

Homework 1

Irene Proietti Cesarini, Giovanni Grieco, Silvia Mucci

Obiettivo del lavoro



**REVISIONE DI 4 CASI D'USO
PER IL WEB EXTRACTION**



**VALUTARE COME I LARGE
LANGUAGE MODEL (LLM)
POSSONO AUTOMATIZZARE
IL LAVORO**



**ANALIZZARE COSTI, LATENZA
E BENEFICI.**

Vertex

- LLM sostituisce gli annotatori umani.
- Identifica automaticamente i campi principali (titolo, prezzo...).
- Genera XPath




Raccolta pagine



Clusterizzazione pagine per struttura pagina



Scelta pagine rappresentative



LLM



Apprendimento regole per l'estrazione



Estrazione automatica

Analisi utilizzo LLM

Costi e Latenza delle soluzioni LLM



Frequenza d'uso:

È utilizzato **su poche pagine per cluster**, solo all'inizio del processo, quindi il numero di chiamate è molto ridotto.



Costo stimato:

Il costo complessivo è **molto basso**, perché l'LLM viene usato pochissime volte.



Latenza:

Ogni chiamata richiede **circa 1–3 secondi per pagina**, quindi l'intera fase di annotazione si completa in meno di un minuto per cluster.



Risultato:

Elimina completamente l'annotazione manuale e **riduce il tempo di annotazione** del sistema da ore a pochi minuti.

Alfred

- Gli LLM rispondono alle domande Sì/No al posto della folla.
- Usano esempi di ground truth per imparare le risposte corrette.




Generazione regole



Applicazione delle regole su più pagine



Valutazione risultati



LLM



Valutazione regole e affidabilità dei workers



Active learning e reclutamento dinamico



Scelta wrapper finale

Analisi utilizzo LLM

Costi e Latenza delle soluzioni LLM



Frequenza d'uso:

Viene chiamato **per ogni membership query**, ma solo durante la fase di validazione.



Costo stimato:

Il costo totale è **alto**. Ipotizziamo che i costi siano superiori ad Amazon Mechanical Turk.



Latenza:

Ogni query richiede **1–3 secondi** e le chiamate possono essere eseguite in parallelo, completando la validazione **in pochi minuti**



Risultato:

Sostituisce completamente la folla, mantenendo la qualità del giudizio ma **riducendo drasticamente tempi e costi**.

Diverse strategie di utilizzo di LLM in Alfred

- Approccio Naive: si da in input all'LLM una pagina web e gli si domanda se l'attributo estratto è quello corretto. Dispendioso in termini di token.
- Approccio Smart (forse): si da in input all'LLM una pagina web, ma gli si fanno più domande su più attributi, risparmiando token.

Conseguenze dell'LLM sul Dynamic Recruitment

Il Dynamic Recruitment sfrutta il risultato empirico per cui $1/3$ dei worker risponde correttamente e che, aggiungendo più worker, la qualità delle regole aumenta.

È vero anche per gli LLM?

- Cosa vuol dire aggiungere più worker di tipo LLM? Approccio ibrido, domande ripetute, modifica degli iperparametri, utilizzo di modelli differenti.
- È vero che aggiungere più LLM incrementa la qualità delle regole? Non abbiamo un risultato empirico equivalente.


WEIR

- LLM genera le regole XPath per ogni attributo su una sola pagina per sorgente.
- Si assume che ogni pagine della stessa sorgente avrà la stessa struttura.

- LLM viene introdotto quando il sistema di matching fallisce nel rilevare i campi semanticamente uguali.



Raccolta dati da più pagine



LLM



Estrazione dati



LLM



Unione dati uguali o simili



Creazione dataset finale

Analisi utilizzo LLM

Costi e Latenza delle soluzioni LLM



Frequenza d'uso:

Ogni sito richiede **circa 5–10 chiamate**, una per ciascun campo da estrarre.



Costo stimato:

Il costo è **basso**, perché il modello viene impiegato solo nella fase di generazione delle regole.



Latenza:

Ogni regola viene generata in **2–5 secondi**, quindi un intero set di regole per un sito si ottiene in **meno di un minuto**.




Risultato:

Permette di **automatizzare la creazione delle regole**, riducendo il lavoro manuale e accelerando la configurazione di nuovi siti.

CERES

- LLM inizializza il knowledge graph estraendo l'entità principale e un attributo "caratterizzante".
- L'assunzione è che il pattern dell'attributo sia ripetuto anche in altre parti della pagina.



LLM



Ricerca del DOM della pagina dove compaiono informazioni o parole simili



Creazione con collegamenti tra etichette e valori



Estensione etichette a parti simili



Aggiornamento grafo

Analisi utilizzo LLM

Costi e Latenza delle soluzioni LLM



Frequenza d'uso:

Serve **solo una volta per pagina o per dominio**, per mappare i concetti principali del Knowledge Graph.




Costo stimato:

Il costo è **molto basso**, poiché l'LLM è utilizzato solo nella fase iniziale e ad ogni variazione di sorgente.



Latenza:

Ogni chiamata richiede **1–2 secondi per campo**, quindi l'intera fase di scoperta dei campi è **rapida e facilmente parallelizzabile**.



Risultato:

Migliora la capacità del sistema di **riconoscere campi e sinonimi** senza bisogno di liste manuali, aumentando la copertura delle informazioni.

Conclusioni

La proposta consiste nell'utilizzare i modelli LLM nelle parti del processo in cui l'essere umano è coinvolto, favorendo una collaborazione sinergica tra intelligenza artificiale e intelligenza umana, in modo che l'LLM supporti l'uomo.