

Ingegneria dei dati 2025/2026

Homework 3

(da svolgere in gruppo)

Paolo Merialdo

Homework 3

Scegliere un articolo da approfondire tra questa lista (per chi frequenta, la scelta è già stata fatta in aula):

- Teong, Kai-Sheng, Lay-Ki Soon, and Tin Tin Su. "Schema-agnostic entity matching using pre-trained language models." CIKM 2020
- Zhang, Yunjia, et al. "Schema Matching using Pre-Trained Language Models." *ICDE* 2023
- Zhang, Haochen, et al. "Jellyfish: A Large Language Model for Data Preprocessing." *arXiv preprint arXiv:2312.01678* (2023)
- Korini, Ketil, and Christian Bizer. "Column Type Annotation using ChatGPT." *arXiv preprint arXiv:2306.00745* (2023)
- Liu, Yurong, Eduardo Pena, Aecio Santos, Eden Wu, and Juliana Freire. "Magneto: Combining small and large language models for schema matching." *arXiv preprint arXiv:2412.08194* (2024).
- Parciak, Marcel, Brecht Vandevoort, Frank Neven, Liesbet M. Peeters, and Stijn Vansummeren. "Schema matching with large language models: an experimental study." *arXiv preprint arXiv:2407.11852* (2024).
- Wang, S., Li, Y., Xiao, H., Dai, B.T., Lee, R.K.W., Dong, Y. and Deng, L., 2025. LLMATCH: A Unified Schema Matching Framework with Large Language Models. *arXiv preprint arXiv:2507.10897*.
- Seedat, Nabeel, and Mihaela van der Schaar. "Bootstrapping Self-Improvement of Language Model Programs for Zero-Shot Schema Matching." *Forty-second International Conference on Machine Learning*.

Homework 3

- Preparare un presentazione di 15' nella quale si descrivano:
 - La formulazione del problema affrontato nell'articolo
 - La soluzione proposta
 - La verifica sperimentale: metriche, dataset, baseline (soluzioni alternative usate come termine di confronto), risultati

Termini di consegna: lunedì 10 novembre ore 11.00 (la presentazione verrà discussa in aula, a lezione).

Caricare la presentazione attraverso il seguente modulo:

<https://forms.office.com/e/EbqR7dvK4>