

Ingegneria dei dati 2025/2026

Homework 4

(da svolgere in gruppo)

Paolo Merialdo

Homework 4

Scegliere un articolo da approfondire tra questa lista (per chi frequenta, la scelta è già stata fatta in aula):

- Teong, Kai-Sheng, Lay-Ki Soon, and Tin Tin Su. "Schema-agnostic entity matching using pre-trained language models." CIKM 2020
- Fu, Jiajie, Haitong Tang, Arijit Khan, Sharad Mehrotra, Xiangyu Ke, and Yunjun Gao. "In-context Clustering-based Entity Resolution with Large Language Models: A Design Space Exploration." *Proceedings of the ACM on Management of Data* 3, no. 4 (2025): 1-28.
- Kannangara, Sandeepa, Arman Abrahamyan, Daniel Elias, Thomas Kilby, Nadav Dar, Luiz Pizzato, Anna Leontjeva, and Dan Jermyn. "A Robust and Efficient Pipeline for Enterprise-Level Large-Scale Entity Resolution." arXiv preprint arXiv:2508.03767 (2025).
- Wang, Tianshu, Xiaoyang Chen, Hongyu Lin, Xuanang Chen, Xianpei Han, Le Sun, Hao Wang, and Zhenyu Zeng. "Match, compare, or select? an investigation of large language models for entity matching." In *Proceedings of the 31st International Conference on Computational Linguistics*, pp. 96-109. 2025.
- Steiner, Aaron, Ralph Peeters, and Christian Bizer. "Fine-tuning large language models for entity matching." In *2025 IEEE 41st International Conference on Data Engineering Workshops (ICDEW)*, pp. 9-17. IEEE, 2025.
- Zhang, Zeyu, Paul Groth, Iacer Calixto, and Sebastian Schelter. *A Deep Dive Into Cross-Dataset Entity Matching with Large and Small Language Models*. 2025.
- Zhang, Zeyu, Paul Groth, Iacer Calixto, and Sebastian Schelter. "AnyMatch--Efficient Zero-Shot Entity Matching with a Small Language Model." *arXiv preprint arXiv:2409.04073* (2024).
- Li, Huahang, Longyu Feng, Shuangyin Li, Fei Hao, Chen Jason Zhang, Yuanfeng Song, and Lei Chen. "On leveraging large language models for enhancing entity resolution." *CoRR* (2024)

Homework 4

- Preparare un presentazione di 15' nella quale si descrivano:
 - La formulazione del problema affrontato nell'articolo
 - La soluzione proposta
 - La verifica sperimentale: dettagliare metriche, dataset, baseline (soluzioni alternative usate come termine di confronto), risultati

Termini di consegna: lunedì 17 novembre ore 11.00 (la presentazione verrà discussa in aula, a lezione).

Caricare la presentazione attraverso il seguente modulo:

<https://forms.office.com/e/EbqB7dvK4>