

Homework 5

Sviluppo di un Sistema di Information Retrieval per Articoli Scientifici con Indicizzazione Granulare di Tabelle e Figure

Giovanni Pio Grieco
Irene Proietti Cesarini
Silvia Mucci

A.A. 2025/2026

Sommario

Il progetto propone un sistema completo di Information Retrieval progettato per l'indicizzazione avanzata di articoli scientifici, focalizzandosi su tabelle e figure come oggetti di ricerca primari. Il sistema implementa una pipeline automatizzata che esegue il fetch asincrono da [arXiv](#) e [PubMed](#), l'estrazione di contenuti tramite regole XPath e l'indicizzazione su **Elasticsearch**. La valutazione sperimentale tramite metrica **nDCG@10** conferma l'efficacia del sistema, evidenziando al contempo le sfide legate alla disponibilità di documenti in formato HTML e alla specificità dei dati estratti.

1 Introduzione

L'obiettivo del progetto è la realizzazione di un sistema di indicizzazione di articoli accademici basato principalmente su regole di estrazione.

Il sistema scarica gli articoli tramite l'interazione con l'API delle sorgenti arXiv e PubMed, estrae tabelle, figure e paragrafi tramite l'utilizzo di regole basate su HTML/XML e indicizza i contenuti all'interno di Elasticsearch.

L'approccio innovativo risiede nel collegamento tra elementi grafici e contesto testuale: tabelle e figure vengono indicizzate integrando i paragrafi che le citano, permettendo query basate sulla semantica del discorso oltre che sulla semplice didascalia. In questo modo, l'utente ottiene risultati di ricerca arricchiti dal testo che contestualizza l'elemento visivo all'interno dell'articolo.

Fa parte del progetto anche un semplice client grafico che permette di interagire con l'indice fornito da Elasticsearch e di consultare direttamente gli articoli tramite l'URL fornito per ogni risultato di ricerca.

Il codice completo del progetto è disponibile al seguente repository GitHub:

<https://github.com/giovanni-grieco/idd.git>

2 Struttura del Progetto

Il sistema è stato progettato con un'architettura modulare, suddivisa in due componenti principali che operano in modo distinto ma complementare: un **Indexer** e un **Client**.

2.1 Indexer

L'Indexer rappresenta il cuore logico del sistema e gestisce l'intera pipeline di elaborazione dei dati.

Oltre a interfacciarsi direttamente con Elasticsearch per la persistenza dei dati, il modulo integra le seguenti funzionalità chiave:

- **Fetch**
- **Extract**
- **Link**
- **Create Index**
- **Destroy Index**
- **Index**

Ogni fase della pipeline è implementata in **script Python** indipendenti, permettendo un'esecuzione modulare, sebbene logicamente sequenziale.

2.1.1 Fetch

Il comando Fetch gestisce il recupero dei documenti dalle sorgenti arXiv e PubMed interfacciandosi con le rispettive API. Nello specifico:

- per quanto riguarda arXiv, il sistema utilizza l'API per l'interrogazione dell'indice e la ricerca dei paper, mentre il download effettivo del contenuto avviene tramite richieste GET HTTP dirette all'URL del documento;
- PubMed, al contrario, fornisce API dedicate sia per la ricerca che per il download dei file in formato XML. È importante notare che non tutti i documenti di PubMed sono scaricabili programmaticamente: l'accesso dipende dalle autorizzazioni concesse dagli autori; in caso di restrizioni, il paper risulta visibile nell'indice ma presenta un corpo di testo vuoto.

L'architettura del modulo Fetch è progettata per essere efficiente e resiliente attraverso tre caratteristiche principali:

- **Asincronicità:** il sistema opera in maniera asincrona, consentendo il download simultaneo da diverse sorgenti;
- **Rate Limiting:** vengono rispettati i limiti di frequenza imposti dai server remoti per evitare blocchi;
- **Caching:** è presente una funzionalità di caching che permette di saltare il download di paper già presenti nel dataset locale.

Durante questa fase vengono generati anche i metadati essenziali, come titolo, lista degli autori e data di pubblicazione. Poiché l'estrazione di tali informazioni direttamente dal corpo dei documenti risulta complessa a causa della mancanza di uno standard di rappresentazione uniforme, il sistema si affida ai dati strutturati forniti direttamente dalle API delle due sorgenti.

2.1.2 Extract

L'estrazione rappresenta una fase cruciale della pipeline, finalizzata al recupero di tabelle, figure e paragrafi dai documenti acquisiti. In particolare, i paragrafi estratti non costituiscono solo contenuto testuale a sé stante, ma vengono impiegati come metadati fondamentali per arricchire l'indicizzazione semantica degli elementi grafici e tabulari.

Per l'estrazione è stato adottato un approccio basato su regole deterministicamente definite. Tale metodologia risulta particolarmente efficace in questo scenario poiché il corpus è limitato a due sole sorgenti (arXiv e PubMed), permettendo così di definire espressioni XPath specifiche. Il sistema

opera una distinzione logica in base alla sorgente di provenienza: vengono applicati set di regole e parser differenti per gestire le peculiarità strutturali proprie.

```
def extract_figures_from_html(html_content: str, paper_id: str) -> list[Figure]:
    # Placeholder for actual HTML parsing and paragraph extraction logic
    figures = []
    soup = bs4.BeautifulSoup(html_content, 'html.parser')
    # extract all paragraph with class ltx_p
    figure_tags = soup.find_all("figure", class_='ltx_figure')
    for figure_tag in figure_tags:
        caption_tag = figure_tag.find('figcaption',
class_='ltx_caption')
        img_tag = figure_tag.find('img')
        if caption_tag and img_tag:
            caption_text = caption_tag.decode_contents().strip()
            figure_id = figure_tag.get('id', 'unknown_id')
            image_url = f"https://arxiv.org/html/{paper_id}#{figure_id}"
            figures.append(Figure(paper_id, figure_id, caption_text,
image_url))
    return figures
```

Figura 1: Metodo per l'estrazione di figure dai paper di arXiv

2.1.3 Link

Le figure e le tabelle, se considerate come entità isolate, presentano una scarsa densità informativa. Per ovviare a questo limite, il sistema utilizza i paragrafi del testo come dati di "contorno" (o contesto) per arricchire l'indicizzazione di ogni risorsa. Il collegamento viene stabilito identificando esplicitamente quali paragrafi citano direttamente una determinata tabella o figura.

Questa associazione segue una relazione **multi-a-molti**: un singolo paragrafo può citare più figure o tabelle contemporaneamente; allo stesso modo, una singola figura o tabella può essere collegata a molteplici paragrafi che la citano in punti diversi del paper.

In questa fase, quindi, il sistema analizza ogni paragrafo per mappare i riferimenti agli oggetti multimediali e salva queste relazioni in un file dedicato.

```
# <a class="ltx_ref" ...
def parse_references(paragraph_text: str) -> list[str]:
    soup = bs4.BeautifulSoup(paragraph_text, 'html.parser')
    references = []
    for a in soup.find_all('a', class_='ltx_ref'):
        ref_id = a.get('href', '').strip('#')
        logger.info(f"Found reference: {ref_id}")
        if ref_id:
            references.append(ref_id)
    return references
```

Figura 2: Metodo per il collezionamento dei file multimediali contenuti in un paragrafo

2.1.4 Create Index

La fase di creazione degli indici è logicamente indipendente dal flusso di elaborazione dei dati; può infatti essere eseguita in qualsiasi momento, sia prima che dopo la sequenza di "Fetch-Extract-Link".

Questo comando predispone l'ambiente su Elasticsearch configurando i tre indici necessari per il progetto:

- **research_papers**: destinato al contenuto testuale e ai metadati degli articoli;
- **tables**: dedicato alla memorizzazione dei dati tabulari e del loro contesto;

- **figures**: riservato alla gestione delle immagini e dei relativi riferimenti testuali.

2.1.5 Destroy Index

Questa funzionalità permette la rimozione integrale degli indici dal server Elasticsearch. Viene utilizzata come fase finale di pulizia o per resettare l'ambiente di lavoro, cancellando permanentemente tutti i dati precedentemente indicizzati.

2.1.6 Index

Il comando di indicizzazione rappresenta la fase operativa in cui i dati vengono effettivamente caricati sul motore di ricerca.

Il sistema aggrega i documenti originali, i metadati estratti e tutte le relazioni di collegamento create nella fase di *Link*, trasferendo il pacchetto informativo completo su Elasticsearch per renderlo interrogabile.

2.2 Client

Il Client è l'interfaccia di front-end che permette all'utente finale di interrogare gli indici creati. Attraverso una GUI intuitiva, l'utente può:

- **Selezionare l'indice** di interesse tra quelli disponibili (research_papers, tables o figures);
- **Inviare query testuali** per recuperare i documenti più rilevanti secondo l'algoritmo di ranking di Elasticsearch;
- **Consultare i risultati**, visualizzando i metadati principali (titolo, autori, data) e accedendo al documento originale tramite un URL diretto che apre il browser di default.




Figura 3: Screenshot della GUI del Client

2.3 Elasticsearch

Il motore di ricerca scelto per il progetto è **Elasticsearch**, eseguito all'interno di un **container Docker** per garantirne la portabilità e la facilità di deployment.

3 Struttura degli Indici

Per garantire una ricerca granulare ed efficace, il sistema utilizza tre indici distinti su Elasticsearch, specializzati per diverse tipologie di contenuto.

3.1 Research Papers

Questo indice è dedicato alla gestione del corpo testuale degli articoli accademici e si compone dei seguenti campi:

- **title**: il titolo dell'articolo (tipo **text**);
- **authors**: la lista degli autori (tipo **keyword**);
- **published**: la data di pubblicazione (tipo **date**);
- **summary**: l'abstract del paper (tipo **text**);
- **link**: l'URL diretto all'articolo originale (tipo **keyword**);
- **content**: il contenuto testuale integrale del documento (tipo **text**).

3.2 Figures

L'indice per le figure mappa gli elementi grafici attraverso i seguenti metadati:

- **figure_id**: identificatore univoco della figura all'interno del paper;
- **caption**: la didascalia descrittiva dell'immagine;
- **paper_id**: riferimento all'articolo di provenienza;
- **url**: indirizzo della figura all'interno del paper;
- **image_url**: (opzionale) URL della sorgente diretta dell'immagine;
- **blob_data**: aggregazione testuale dei paragrafi che citano la figura.

3.3 Tables

L'indice per le tabelle segue una struttura analoga per favorire la coerenza del sistema:

- **table_id**: identificatore della tabella nel contesto del paper;
- **caption**: la didascalia della tabella;
- **paper_id**: identificatore dell'articolo accademico correlato;
- **data**: il contenuto strutturato della tabella;
- **table_url**: URL della risorsa all'interno del documento;
- **blob_data**: aggregazione testuale dei paragrafi citanti.

3.4 Strategia "Blob Data"

La sfida principale del progetto risiede nell'indicizzazione di informazioni non prettamente testuali o difficilmente processabili, come il contenuto grezzo di una tabella o un'immagine. Per superare questo limite, è stata adottata la strategia del **Blob Data**, che consiste nello sfruttare il contesto semantico fornito dagli autori degli articoli.

Il campo `blob.data` è una stringa di grandi dimensioni in cui vengono concatenati sistematicamente tutti i paragrafi che citano esplicitamente una determinata risorsa.

Poiché l'utente interagisce con il sistema esclusivamente tramite query testuali, questa assunzione permette a Elasticsearch di recuperare figure o tabelle rilevanti analizzando il discorso scientifico che le circonda e le descrive, rendendo di fatto "parlanti" oggetti che altrimenti sarebbero opachi al motore di ricerca.

4 Dataset

Il dataset complessivo è costituito da un totale di **398 articoli** provenienti da **arXiv** e **2996 articoli** estratti da **PubMed Central**.

Sebbene il numero di documenti individuati sia elevato, la reale disponibilità dei dati per l'indicizzazione è stata influenzata da vincoli tecnici e legali propri di ciascuna sorgente.

4.1 Limitazioni e Reperibilità

La costruzione del corpus ha dovuto affrontare due principali criticità:

- **Restrizioni su PubMed:** l'API di PubMed Central rispetta la volontà degli autori riguardo alla distribuzione dei contenuti. Non tutti i ricercatori autorizzano lo scaricamento programmatico dei propri lavori; in questi casi, il sistema recupera i metadati ma il "corpo" del paper risulta vuoto, rendendo di fatto l'articolo non indicizzabile ai fini della ricerca full-text;
- **Formati su arXiv:** per quanto riguarda la sorgente arXiv, l'indicizzazione è strettamente dipendente dalla disponibilità della versione HTML dei documenti. Poiché non tutti gli articoli dispongono di questo formato (molti sono distribuiti esclusivamente in PDF), una parte dei paper identificati è stata necessariamente scartata durante la pipeline di estrazione.

Questi fattori hanno circoscritto il perimetro del dataset finale, limitando l'indicizzazione ai soli documenti che garantissero un accesso completo e strutturato al contenuto testuale e multimediale.

5 Analisi del Sistema

Per valutare il comportamento del motore di ricerca, sono state definite query specifiche volte ad analizzare la risposta del sistema in diverse condizioni di reperibilità dei dati.

5.1 Vincoli e Specificità del Corpus

Il sistema opera su un dominio di informazioni circoscritto dai requisiti di progetto, basato su argomenti specifici estratti dalle sorgenti.

Nello specifico:

- per **arXiv**, sono stati selezionati gli articoli rispondenti alla query "text-to-SQL OR Natural Language to SQL";
- per **PubMed** la ricerca è stata focalizzata su "glyphosate AND cancer risk".

5.2 Analisi del Bias Temporale

Questa selezione ha introdotto un **bias temporale** significativo.

I dati mostrano una chiara correlazione tra la data di pubblicazione e la disponibilità del formato HTML su arXiv, che risulta essere una caratteristica presente quasi esclusivamente negli articoli più recenti (a partire dal 2021).




Figura 4: Distribuzione temporale degli articoli su arXiv

Questa distribuzione influenza direttamente la tipologia di contenuti estratti.

Negli articoli più recenti sui temi "Natural Language" e "Text-to-SQL", domina l'utilizzo dei **Large Language Models (LLM)**. Di conseguenza, il contenuto di tabelle e figure si è evoluto: se in passato prevalevano schemi di database o architetture classiche, oggi si riscontra una prevalenza di esempi relativi al **prompt engineering**.

5.3 Definizione delle Query di Test

Per testare la robustezza del sistema, sono state concepite query con diversi gradi di aderenza semantica al dataset:

- **Query ad elevata vicinanza:** come "text-to-SQL models: recent methods and benchmarks", molto attinente ai documenti effettivamente indicizzati da arXiv;
- **Query a bassa vicinanza:** come "climate change statistics tables: temperature, sea level", volutamente distante dalle tematiche trattate (specialmente per PubMed), utile per valutare le prestazioni del sistema in assenza di documenti pertinenti.

6 Valutazione del Sistema

L'efficacia del sistema è stata misurata analizzando la pertinenza dei primi 10 risultati (**Top-10**) restituiti per ogni interrogazione. Nello specifico, il protocollo di test ha previsto l'esecuzione di 5 query distinte per ciascuno dei tre indici implementati.

La pertinenza è stata valutata da operatori umani tramite un responso binario per ogni risultato. Tuttavia, va sottolineato che i valutatori non sono necessariamente esperti del dominio scientifico trattato, fattore che potrebbe influenzare l'attendibilità assoluta della valutazione.

Per riflettere l'importanza della posizione dei risultati, è stata utilizzata la metrica **nDCG@10** (*normalized Discounted Cumulative Gain*).

ID	Index	Query	nDCG@10
RP1	research_papers	"text-to-SQL models: recent methods and benchmarks"	1.0
RP2	research_papers	"Natural language to SQL: datasets, evaluation, and challenges"	0.98
RP3	research_papers	"glyphosate exposure AND cancer risk epidemiology meta-analysis"	0.94
RP4	research_papers	"machine learning models for cancer prediction F1 score comparison"	0.86
RP5	research_papers	"climate change impact models and attribution studies"	0.86
T1	tables	"SQL schema examples and example query results tables"	0.49
T2	tables	"neural network benchmark tables: accuracy, F1, precision"	0.96
T3	tables	"climate change statistics tables: temperature, sea level"	0.62
T4	tables	"cancer prediction model metrics table F1 precision recall"	0.67
T5	tables	"glyphosate assay results table exposure dose response"	0.95
F1	figures	"visualizations of text-to-SQL architecture or pipeline"	0.74
F2	figures	"neural network training curves and confusion matrices"	0.94
F3	figures	"climate change maps and trend plots"	0.63
F4	figures	"ROC and PR curves for cancer prediction models"	0.91
F5	figures	"glyphosate exposure dose-response charts"	0.94

Figura 5: Tabella contenente le query effettuate sul sistema durante la valutazione

6.1 Analisi dei Risultati

Dall'analisi dei dati emerge che le prestazioni sono ottimali per l'indice **research_papers**, mentre si riscontra un calo qualitativo negli indici **figures** e **tables**. Tale fenomeno è riconducibile alla strategia di indicizzazione basata sul campo **blob_data**: l'uso dei paragrafi citanti come unica fonte di contesto per Elasticsearch potrebbe non essere sempre sufficiente a discriminare correttamente il contenuto degli oggetti multimediali.

Inoltre, si osserva:

- **Query T1**: il punteggio ridotto (0.49) è dovuto alla scarsità di tabelle contenenti "esempi di schema" nel dataset. Molti falsi positivi riguardavano tabelle su *prompt-engineering*, a conferma del bias temporale;
- **Query T3**: le performance diminuiscono poiché gli articoli estratti da PubMed non trattano direttamente il tema del "cambiamento climatico". In assenza di documenti realmente pertinenti a priori, il sistema propone risultati con bassa rilevanza semantica.

7 Conclusioni

La valutazione complessiva del sistema evidenzia una dicotomia nelle prestazioni: il motore di ricerca si dimostra estremamente efficace nel gestire query convenzionali, ma presenta delle criticità quando sottoposto a interrogazioni più specifiche.

Risulta complesso determinare se il calo di precisione per le query meno comuni sia imputabile a limiti strutturali dell'architettura o alla mancanza intrinseca di documenti pertinenti all'interno del dataset raccolto.

Un ulteriore elemento di riflessione riguarda l'adozione di un approccio *human-in-the-loop* per la valutazione della rilevanza. Tale metodologia introduce una variabile soggettiva legata alla competenza specifica nel dominio: la pertinenza dei risultati è stata infatti valutata dagli autori della presente relazione, i quali non possiedono un background medico specialistico.

Questo limite potrebbe aver influenzato la validazione dei risultati, specialmente per gli articoli provenienti dalla sorgente PubMed.

In conclusione, sebbene la strategia di arricchimento tramite il contesto testuale dei paragrafi citanti rappresenti un passo avanti nell'indicizzazione di oggetti multimediali, lo sviluppo futuro del sistema potrebbe beneficiare di tecniche di valutazione più oggettive e di una base documentale più vasta ed eterogenea.