

Ingegneria dei dati 2025/2026

Homework 5

(da svolgere in gruppo)

Paolo Merialdo

Homework 5

L'obiettivo del progetto è sviluppare un sistema avanzato di *search* su articoli scientifici, in cui le tabelle siano trattate come oggetti di prima classe e completamente indicizzabili.

- 1. Creazione del corpus di documenti.** Scrivere uno script per recuperare da <https://arxiv.org> tutti gli articoli disponibili in formato HTML il cui titolo o abstract contiene la stringa:
 1. Gruppi A: *"Entity resolution"* oppure *"Entity matching"*.
 2. Gruppi B: *"text-to-sql"* oppure *"Natural language to sql"*
 3. Gruppi C: *"automatic speech recognition"* oppure *"speech to text"*
 4. Gruppi C: *"text to speech"*
 5. Studenti lavoratori: *"Query processing"* oppure *"Query optimization"*
- 2. Indicizzazione dei documenti.** Scrivere il codice per indicizzare gli articoli utilizzando Elasticsearch (o Lucene), includendo i seguenti campi: titolo, autori, data, abstract, testo completo.
- 3. Funzionalità di ricerca base.** Il sistema deve permettere interrogazioni su uno o più campi, ricerca per parole chiave, combinazioni di query (es. ricerca booleana, full-text). Le funzionalità di ricerca devono essere disponibili tramite una semplice shell su riga di comando e tramite una semplice interfaccia web.
- 4. Estrazione delle tabelle.** Scrivere il codice per estrarre dagli articoli del corpus tutte le tabelle con associati dati di contesto. In particolare, per ogni tabella, estrarre il corpo, la caption, i paragrafi che la citano, i paragrafi che contengono termini presenti nella tabella o nella caption (evitando di considerare termini non informativi).
- 5. Estrazione delle figure.** Scrivere il codice per estrarre dagli articoli del corpus tutte le figure con associati dati di contesto. In particolare, per ogni figura, estrarre l'url, la caption, i paragrafi che la citano, i paragrafi che citano termini presenti nella caption (evitando di considerare termini non informativi).
- 6. Indicizzazione delle tabelle.** Scrivere il codice per indicizzare le tabelle utilizzando Elasticsearch (o Lucene). Ogni tabella viene indicizzata come un documento, con i seguenti campi: `paper_id` (ID dell'articolo), `table_id` (ID della tabella all'interno dell'articolo), `caption` (testo della caption della tabella), `body` (contenuto della tabella come testo), `mentions` (lista dei paragrafi del paper che citano la tabella), `context_paragraphs` (lista dei paragrafi del paper che contengono termini presenti nella tabella o nella caption).
- 7. Indicizzazione delle figure.** Scrivere il codice per indicizzare le figure utilizzando Elasticsearch (o Lucene). Ogni figura viene indicizzata come un documento, con i seguenti campi: `url` (url della figura), `paper_id` (ID dell'articolo), `table_id` (ID della figura all'interno dell'articolo), `caption` (testo della caption della figura), `mentions` (lista dei paragrafi del paper che citano la figura).
- 8. Funzionalità di ricerca avanzate.** Il sistema deve permettere interrogazioni per tabelle, figure, documenti su uno o più campi, ricerca per parole chiave, combinazioni di query (es. ricerca booleana, full-text). Le funzionalità di ricerca devono essere disponibili tramite una semplice shell su riga di comando e tramite una semplice interfaccia web.

Homework 5

- Ripetere le stesse operazioni, per almeno 500 articoli open access presenti su PubMed che contengono le keyword
 - Gruppi 1: *"cancer risk AND coffee consumption"*
 - Gruppi 2: *"glyphosate AND cancer risk"*
 - Gruppi 3: *"air pollution AND cognitive decline"*
 - Gruppi 4: *"ultra-processed foods AND cardiovascular risk"*
- Si possono ottenere da questo url: https://pmc.ncbi.nlm.nih.gov/search/?filter=collections.open_access

Homework 5

- Preparare una relazione di circa 10 pagine che descrive la soluzione tecnica implementata. Descrivere l'architettura della soluzione, e gli esperimenti per valutare le prestazioni (in termini qualitativi e quantitativi) del sistema
- Preparare una presentazione di 15' (che descrive architettura e valutazione sperimentale della soluzione)

Termini di consegna: ore 12:00 il giorno dell'esame

Caricare la relazione e la presentazione attraverso il seguente modulo:

<https://forms.office.com/e/EbqbR7dvK4>